Information Retrieval

01 – Introduction

Philipp Schaer

2025-04-03 – Cologne, Germany https://ir.web.th-koeln.de





Information Retrieval in a Nutshell

- Eine vage Anfrage.
 - Ausdruck eines komplexen
 Informatinsbedürfnisses: Meist eine Frage
- Milliarden von Dokumenten.
 - Texte, Bilder, Audio-Dateien, Videos, ...

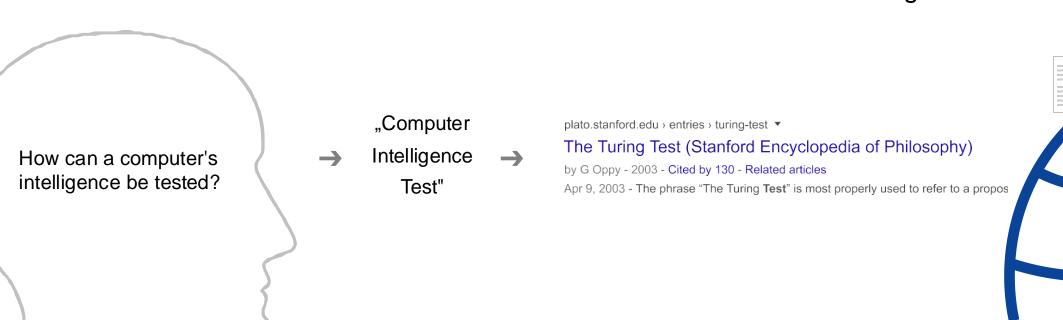
How can a computer's intelligence be tested?



Information Retrieval in a Nutshell

- Eine vage Anfrage.
 - Ausdruck eines komplexen
 Informatinsbedürfnisses: Meist eine Frage
- Finde relevante Dokumente in Millisekunden!

- Milliarden von Dokumenten.
 - Texte, Bilder, Audio-Dateien, Videos, ...
- Hohes Ungleichgewicht.
 - Nur ein winziger Bruchteil aller Dokumente ist für die Anfrage relevant.



Im Information Retrieval suchen wir also die Nadel im ...



Und das macht nicht nur Google...!



























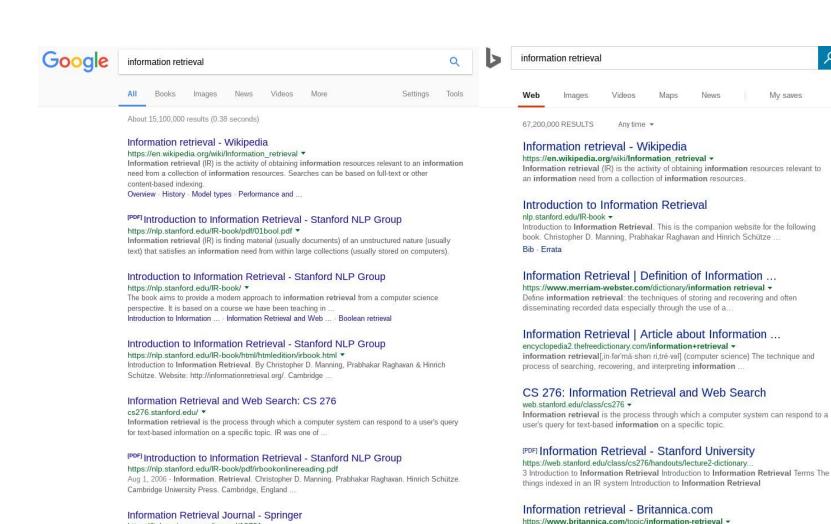


information retrieval: Recovery of information, especially in a database stored in a

computer. Two main approaches are matching words in the guery against the .

Ein Beispiel...

- Sie möchten alles wissen, was es zum Thema Information Retrieval gibt.
- Sie suchen Texte, die 'information' und 'retrieval' beinhalten.



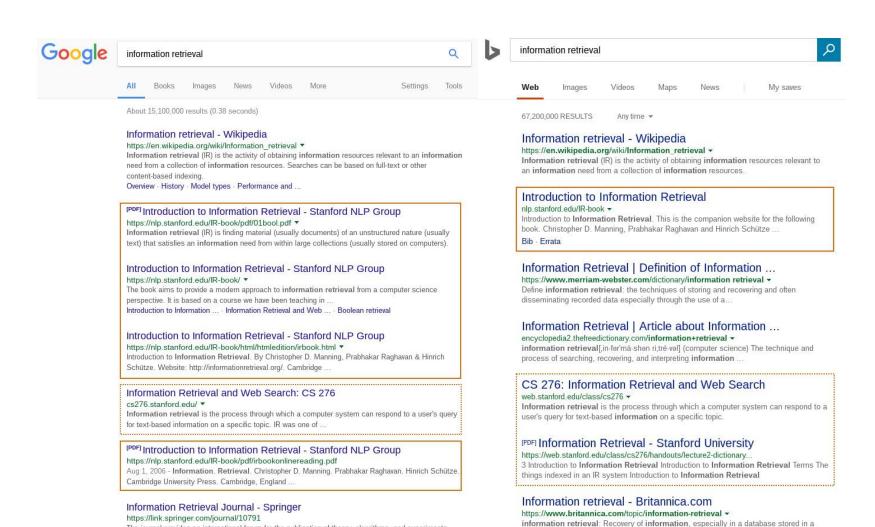
https://link.springer.com/journal/10791

across the broad area of information retrieval. Topics of ...

The journal provides an international forum for the publication of theory, algorithms, and experiments

Ein Beispiel...

- Sie möchten alles wissen, was es zum Thema Information Retrieval gibt.
- Sie suchen Texte, die 'information' und 'retrieval' beinhalten.



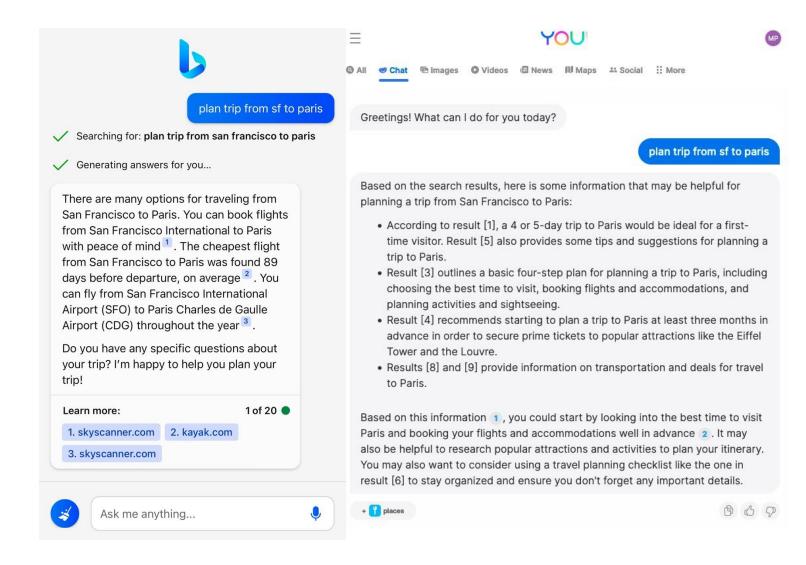
computer. Two main approaches are matching words in the guery against the .

The journal provides an international forum for the publication of theory, algorithms, and experiments

across the broad area of information retrieval. Topics of

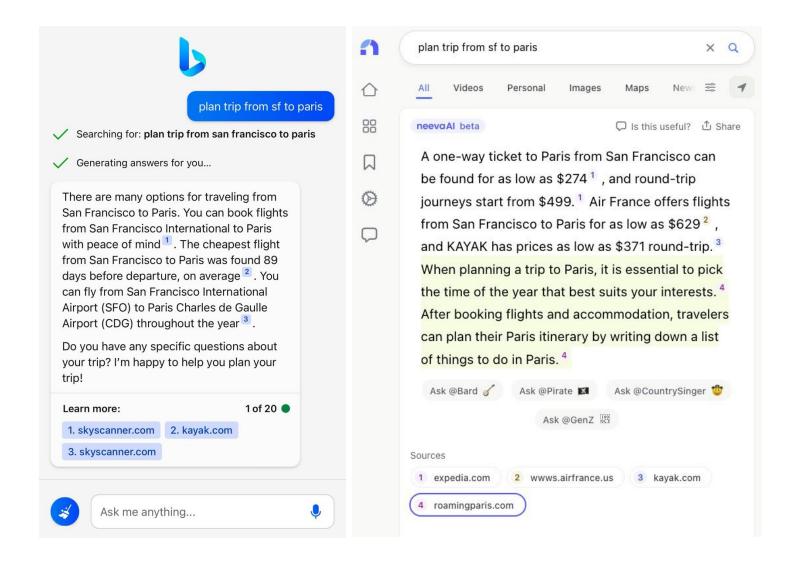
Ein weiteres Beispiel...

- Müssen wir wirklich so viele Ergebnisse überprüfen?
- Das geht doch heute viel einfacher... z.B. mit ChatGPT oder Bing oder Perplexity oder ...



Ein weiteres Beispiel...

- Müssen wir wirklich so viele Ergebnisse überprüfen?
- Das geht doch heute viel einfacher... z.B. mit ChatGPT oder Bing oder Perplexity oder ...



Begrifflichkeiten

In der Informationswissenschaft unterscheiden wir Daten, Information und Wissen.

Definition 1 (Daten, data)

Eine auf einem Speichermedium aufgezeichnete Folge von Symbolen.

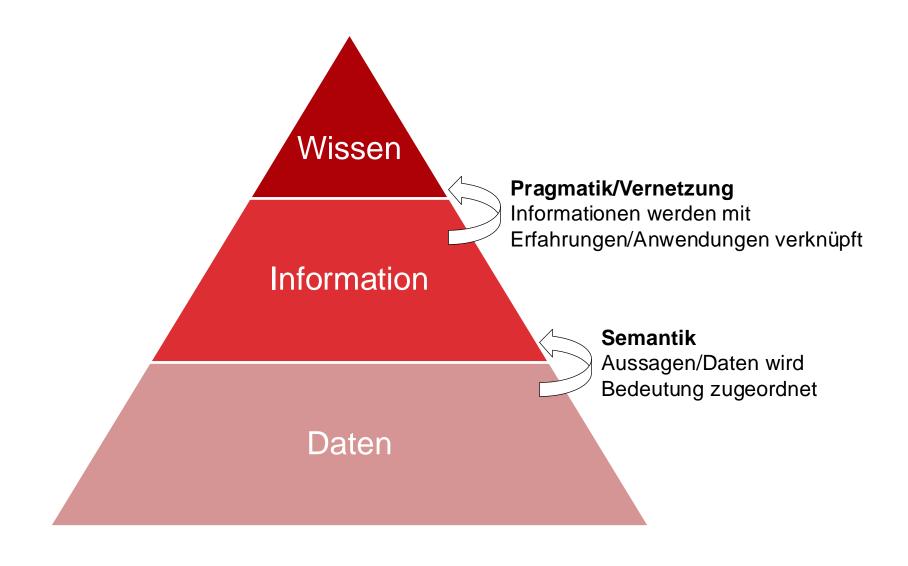
Definition 2 (Information)

Daten, die nützlich sind, wobei "nützlich" z.B. aussagekräftig, interpretierbar, sachlich, usw. ist.

Definition 3 (Wissen, knowledge)

- Wissen ist ein Gedanke, der (unserer begründeten Überzeugung nach) wahr ist.
- Wissen entsteht aus Informationen und befähigt den Wissenden zum Handeln.

Daten – Information – Wissen



Weitere Begrifflichkeiten

Definition 4 (Informationssystem, information system)

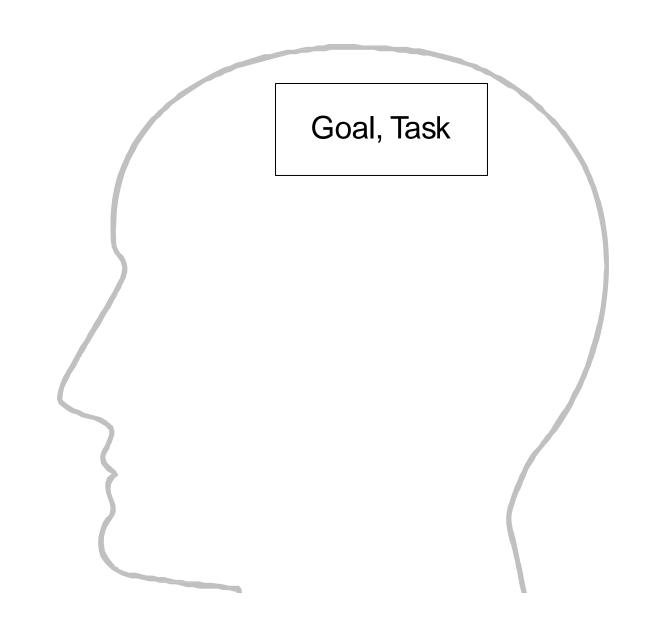
• Ein System zum Sammeln, Erstellen, Speichern, Verarbeiten und Verteilen von Informationen, einschließlich Hard-/Software, Betreiber, Nutzer und der Daten selbst.

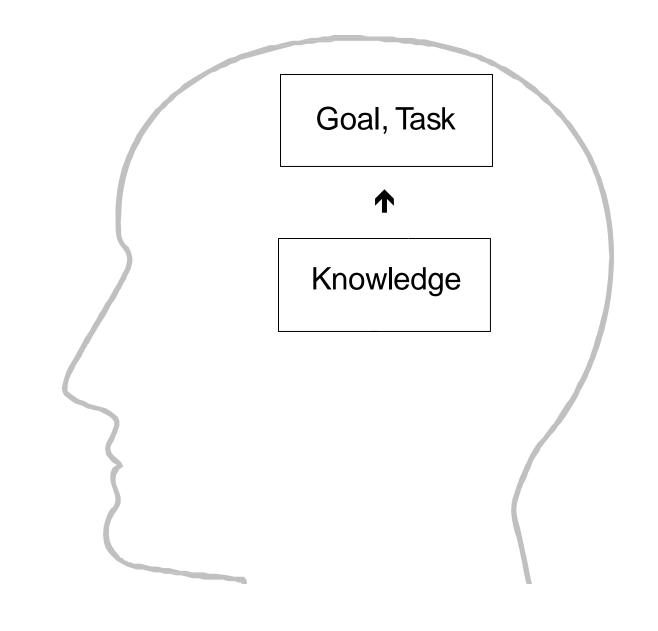
Definition 5 (Informationsbedarf, information need)

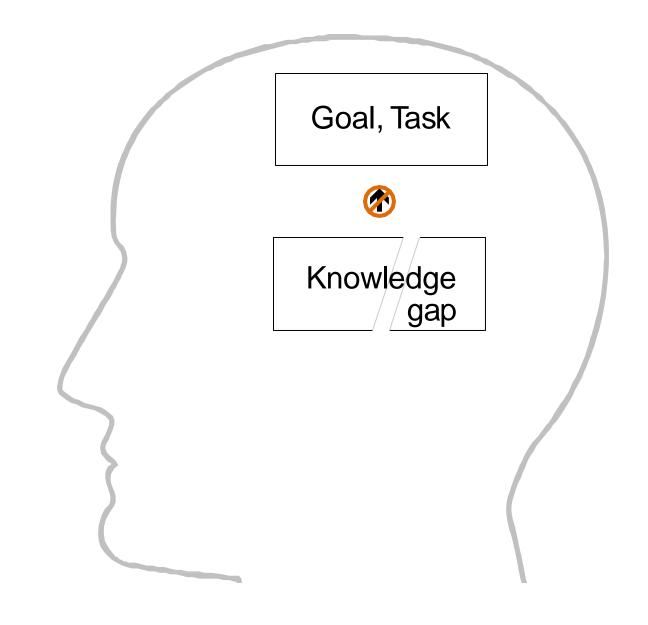
 Der Wunsch eines Benutzers, Informationen zu finden und zu erhalten, um ein bewusstes oder unbewusstes Ziel zu erreichen.

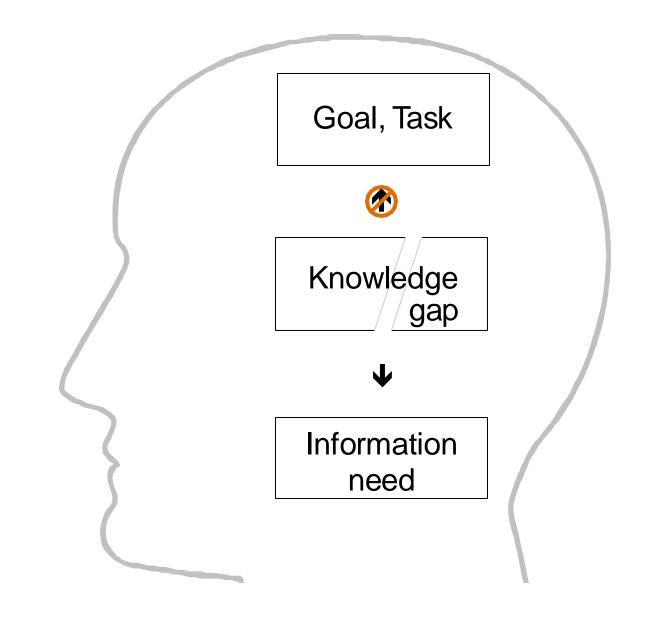
Definition 6 (Relevanz, relevance)

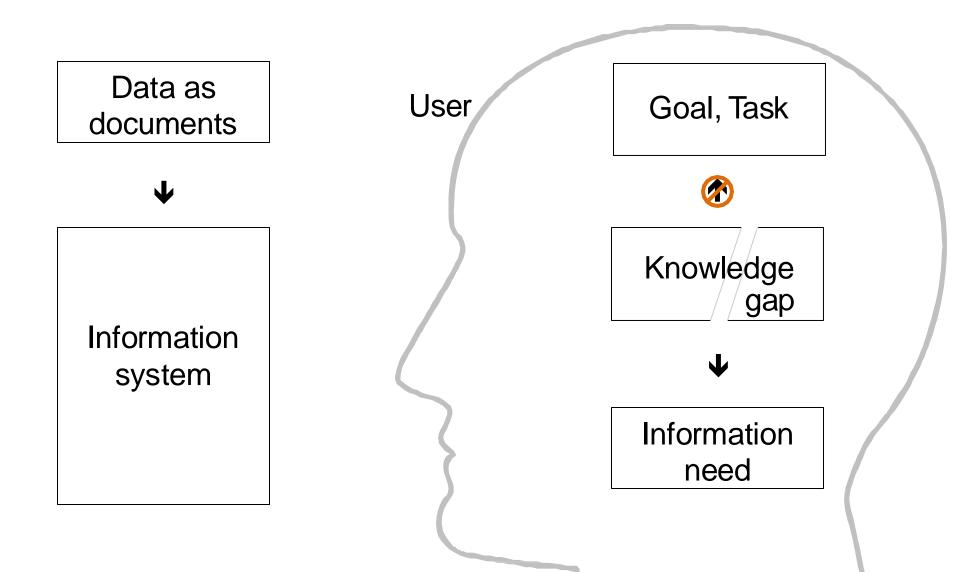
- Der Grad zu dem Ergebnisse das Informationsbedürfnis des Suchenden befriedigen.
- Ein Teil der Daten wird als relevant bezeichnet, wenn er zur Befriedigung eines bestimmten Informationsbedürfnisses (teilweise) nützlich ist. Je näher sie der Befriedigung des Nutzers kommen, desto relevanter sind sie.

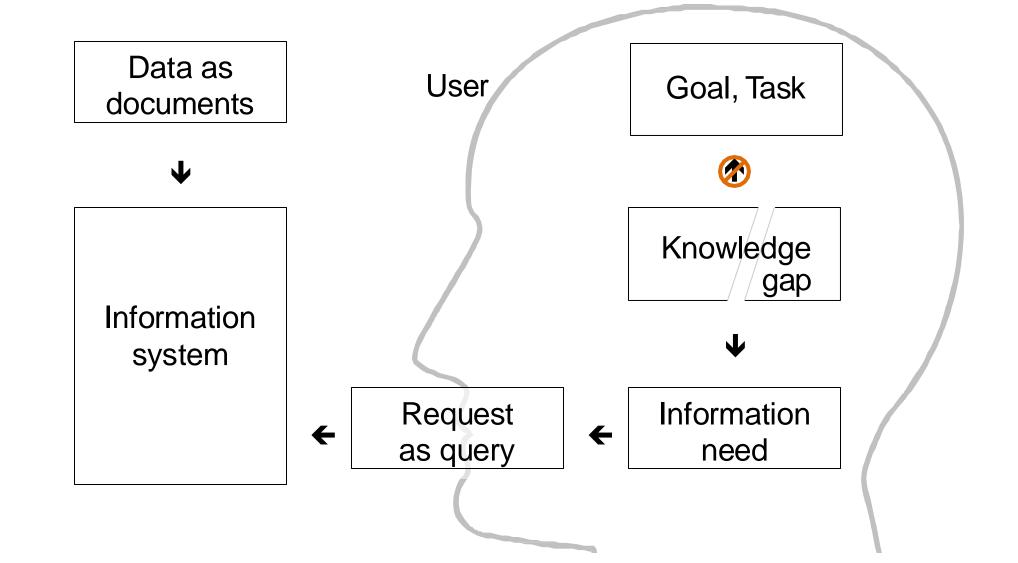


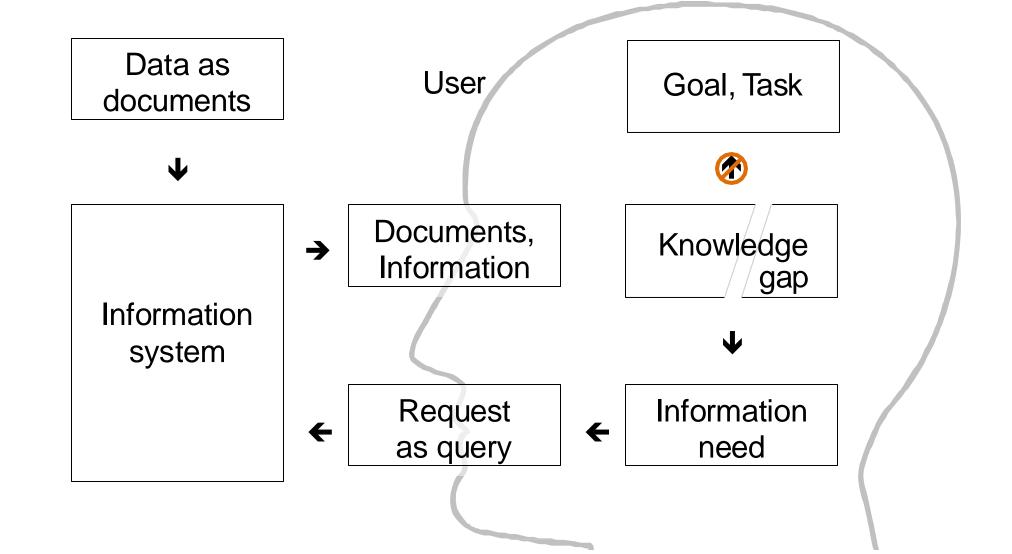


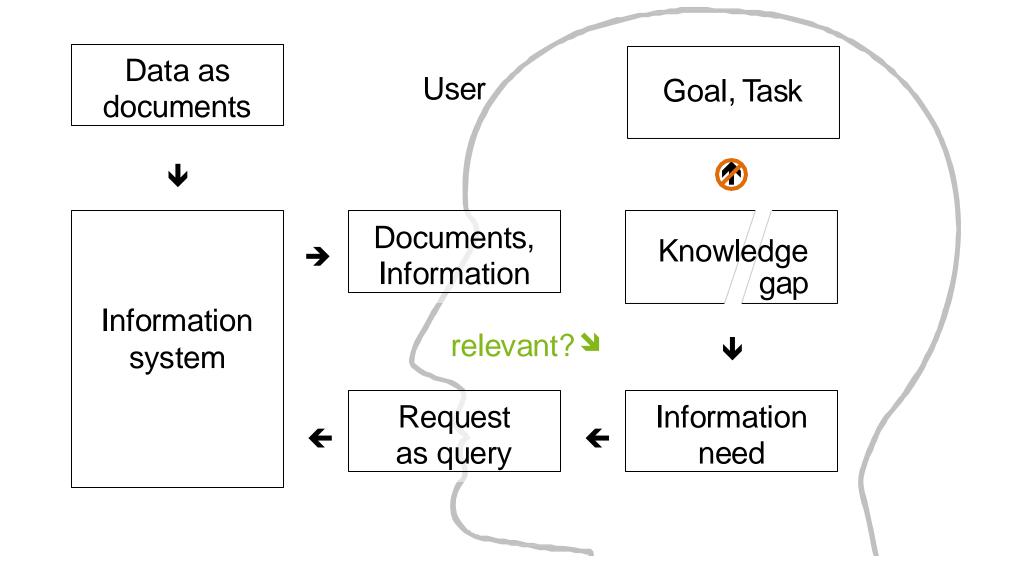


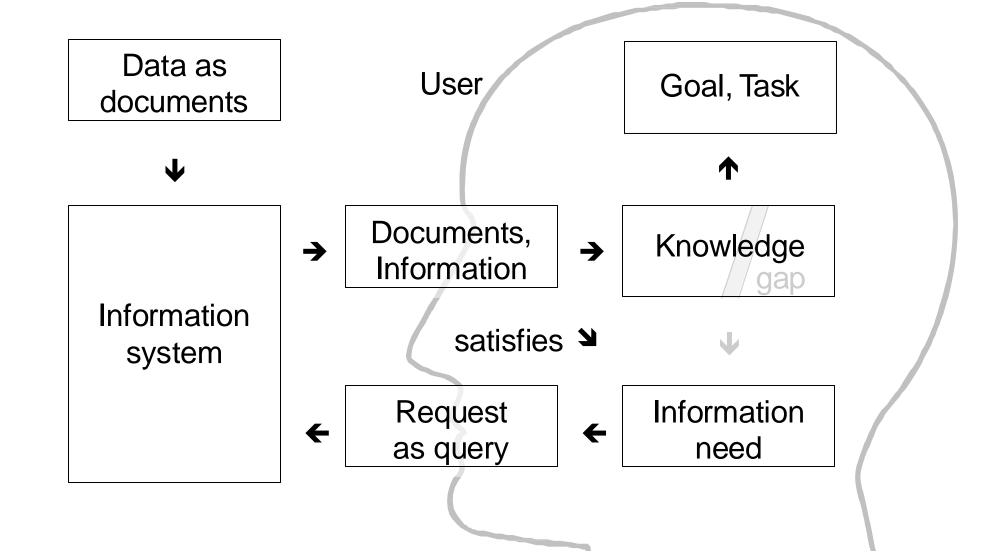


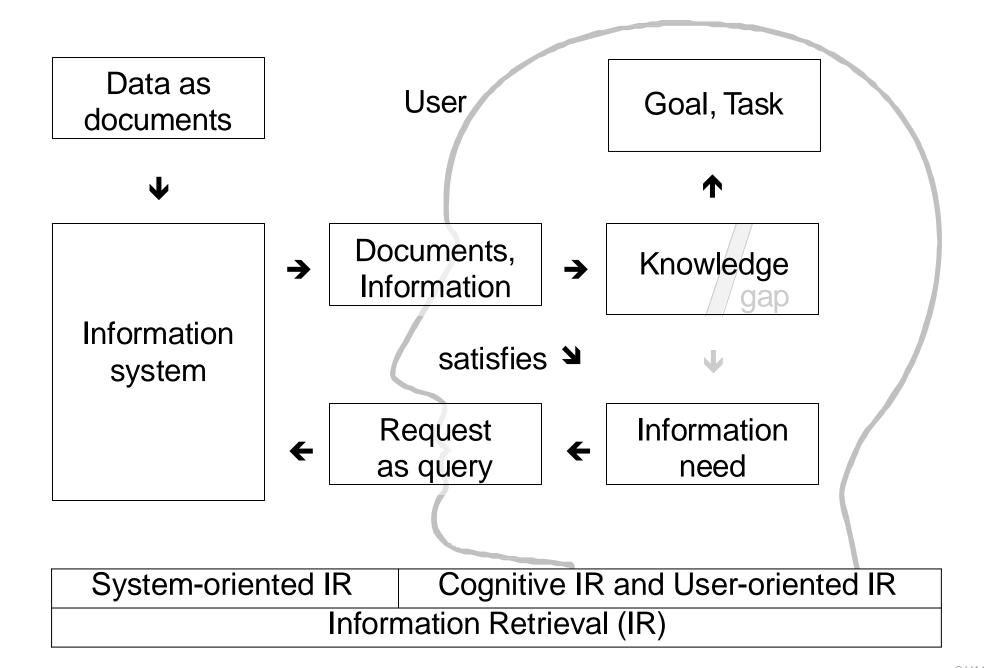












Was ist also nun Information Retrieval?

Definition 7 (Information Retrieval, IR)

- Beschreibt den Akt der Beschaffung von Informationen aus Daten, die für einen Informationsbedürfnis relevant sind.
- Als Forschungsgebiet untersucht Information Retrieval die Rolle und Funktion von Informationssystemen bei der Übertragung von Wissen über Daten sowie die Konzeption, Implementierung, Bewertung und Analyse solcher Systeme.

Was ist also nun Information Retrieval?

Definition 7 (Information Retrieval, IR)

- Beschreibt den Akt der Beschaffung von Informationen aus Daten, die für einen Informationsbedürfnis relevant sind.
- Als Forschungsgebiet untersucht Information Retrieval die Rolle und Funktion von Informationssystemen bei der Übertragung von Wissen über Daten sowie die Konzeption, Implementierung, Bewertung und Analyse solcher Systeme.

Die Probleme dabei sind (u.a.):

- Vage Anfrage (ohne klares Ziel, uneinheitliche Sprache, usw.)
- Unvollständiges und unsicheres Wissen (z.B. Bias durch politische Einstellungen)
- Genauigkeit der Ergebnisse und Effektivität
- Effizienz

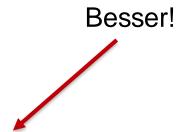
Weitere Definitionen von IR

Drei weitere Definitionen (von vielen)

- "Information retrieval (IR) is finding material (usually documents) of an unstructured nature (usually text) that satisfies an information need from within large collections (usually stored on computers)." (Manning et al., 2008)
- "Information retrieval (IR) is a field concerned with the design, development, and evaluation of interactive systems that help users find information." (Arguello, 2017)
- "Information retrieval is a field concerned with the structure, analysis, organization, storage, and retrieval of information." (Salton, 1968)

Weitere Definitionen von IR

Drei Definitionen (von vielen)



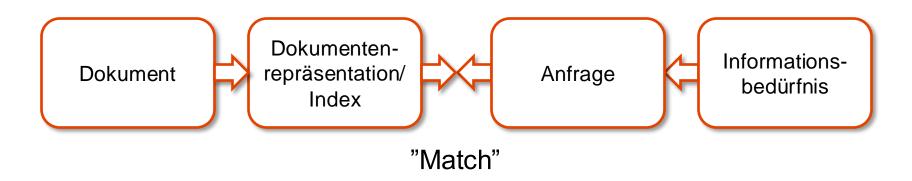
- "Information retrieval (IR) is finding material (usually documents) of an unstructured nature (usually text) that satisfies an information need from within large collections (usually stored on computers)." (Manning et al., 2008)
- "Information retrieval (IR) is a field concerned with the design, development, and evaluation of interactive systems that help users find information." (Arguello, 2017)
- "Information retrieval is a field concerned with the structure, analysis, organization, storage, and retrieval of information." (Salton, 1968)

Klassisches Information Retrieval-Modell

Das klassische Ad-Hoc-Retrieval basiert auf Abgleich von

- Dokumenttermen (Document Representation) und
- Anfragetermen (Query).

Im klassischen Information Retrieval-Modell sind das Informationsbedürfnis als auch die Anfrage starr und verändern sich nicht.



Strukturierte Daten



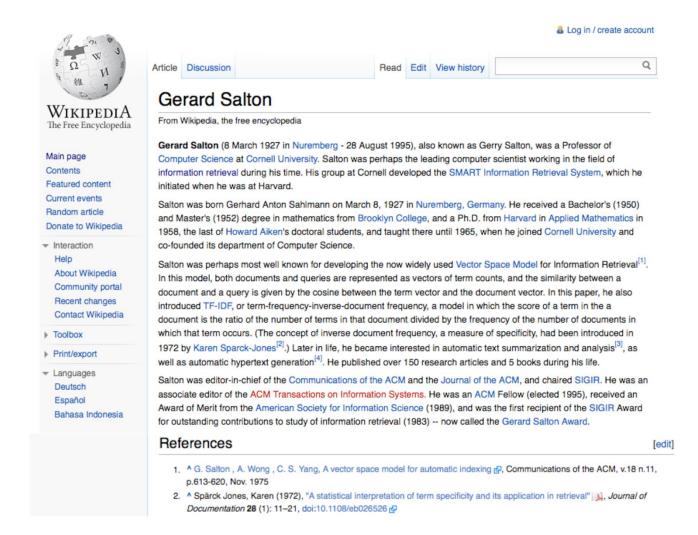
Strukturierte Daten sind z.B. Tabellendaten

| Angestellter | Boss | Gehalt |
|----------------------|-----------------|--------|
| Berthold Heisterkamp | Bernd Stromberg | 50000 |
| Ulf Steinke | Bernd Stromberg | 60000 |
| Sinan Turçulu | Timo Becker | 50000 |

- Numerische Anfragen und Exact Match sind möglich (wie in SQL), bspw.: Gehalt < 60000 AND Boss = Timo Becker</p>
- Toll, aber meistens nicht das was wir im Information Retrieval vorfinden
 - → Wir suchen in unstrukturierte Daten!

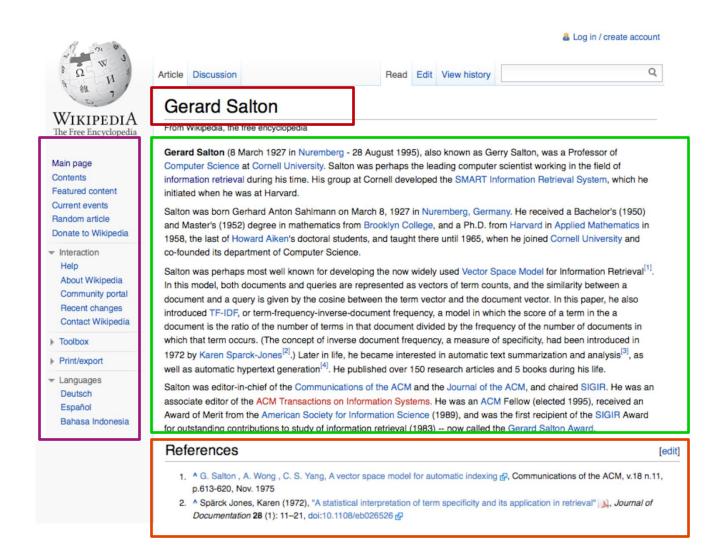
Unstrukturierte Daten...





Das Dokument ist teilstrukturiert...





Dokumentenstrukturen



a Log in / create account

8 n.11.

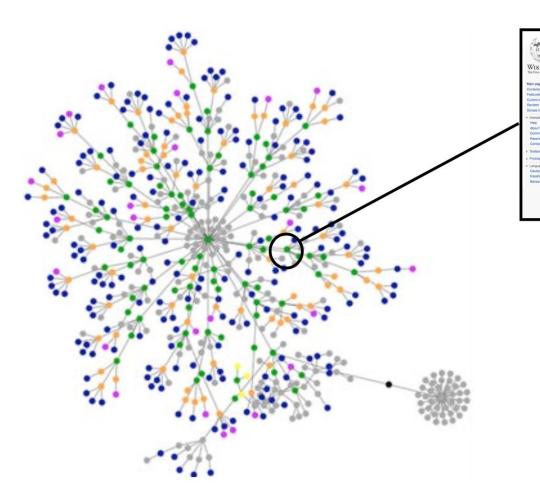
Es gibt zwar eine Struktur, aber der für uns wichtige Teil ist der <u>Text des Artikels</u>. Der Text hat nur **wenig bzw. gar keine Struktur**, die der Computer verstehen könnte.

Allerdings wird sich herausstellen, dass es für eine Suchmaschine gar nicht notwendig ist, den Text "zu verstehen" um eine Anfrage z.B. nach "Gerald Salton" mit relevanten Ergebnissen zu beantworten. Es reichen uns unstrukturierte/semi-strukturierte Daten!

Documentation 28 (1): 11–21, doi:10.1108/eb028526 g

Kollektionsstrukturen

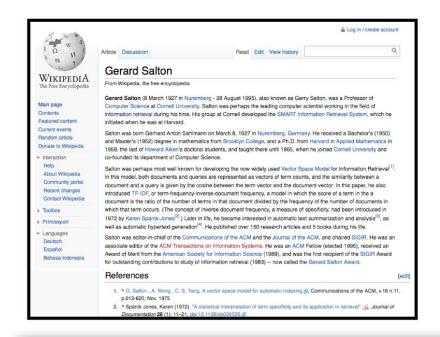




According Section 19 Processors 19 Processor 19 Processors 19 Processors

Strukturen durch Klassifikationen

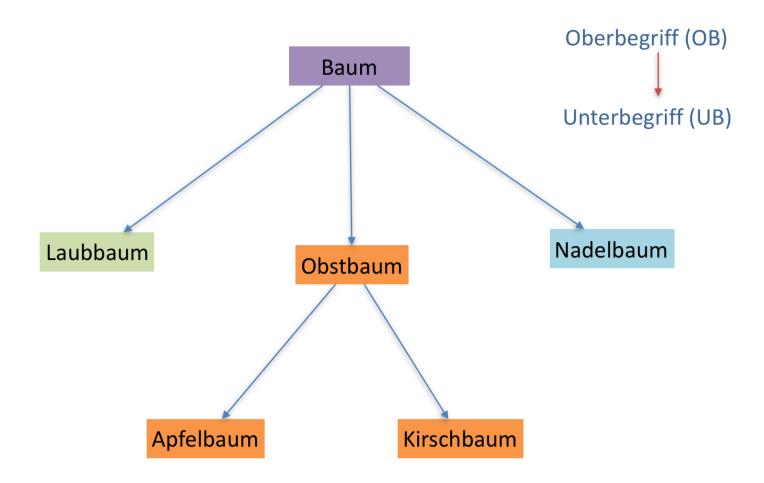




Categories: 1927 births I 1995 deaths I American computer scientists I Computer pioneers I Harvard University alumni I Harvard University faculty I Cornell University faculty I Fellows of the Association for Computing Machinery I Guggenheim Fellows

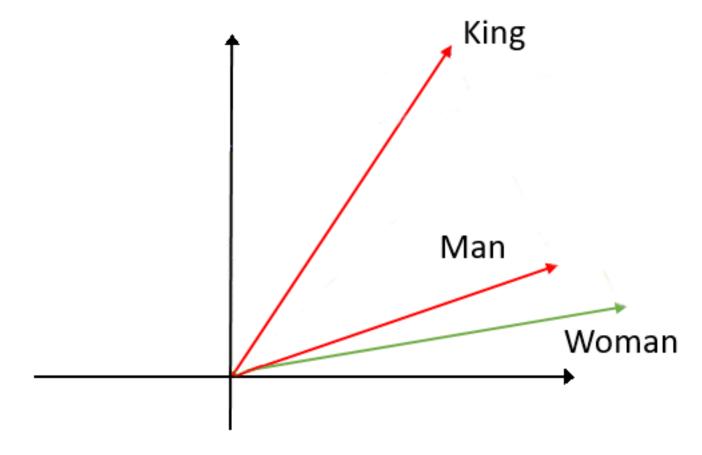
Semantische Strukturen durch Konvention





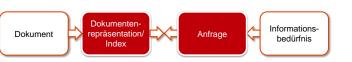
Semantik durch statistische Analyse





 $X = woman + king - man \approx queen$

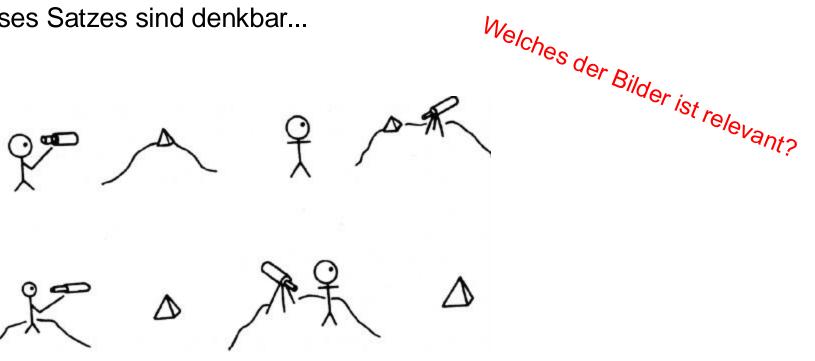
Was ist eigentlich Relevanz?



Schwierig, da Anfrage gerne sehr vage sind.

"The man saw the pyramid on the hill with the telescope."

Viele Interpretationen dieses Satzes sind denkbar...



Anfragen sind nur eine Krücke



Eine Suchanfrage ist nur eine verkürzte Beschreibung des Informationsbedürfnisses des Nutzers.

- Mehrdeutig und eigentlich nur für den Nutzer selbst verständlich
- Eine Anfrage und ein Informationsbedürfnis setzt eine konkrete Aufgabe voraus
- Der Nutzer befindet sich in einem konkreten Kontext, den wir nicht kennen

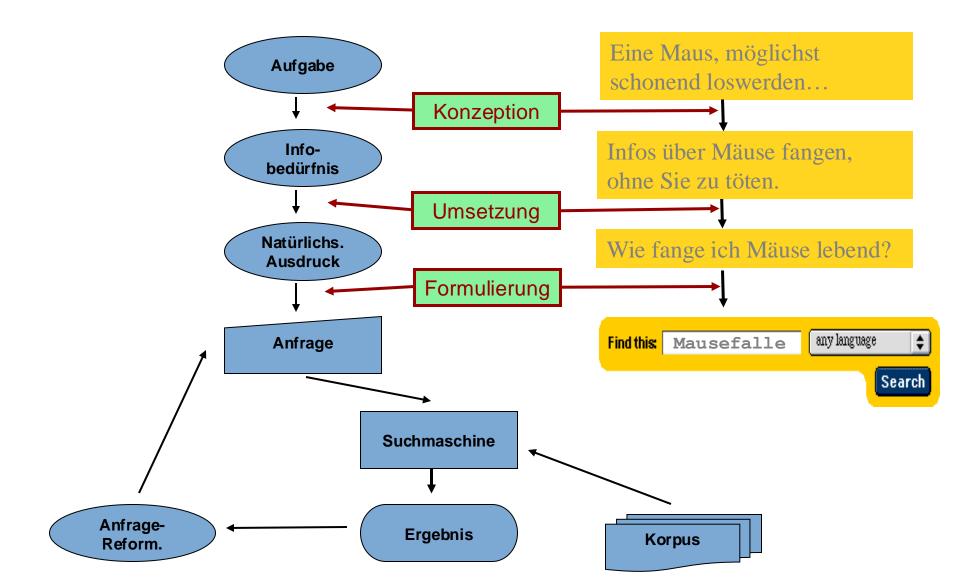
AOL-Logdateien – User 1515830



chai tea calories calories in bananas aftermath of incest how to tell your family you're a victim of incest pottery barn curtains surgical help for depression oakland raiders comforter set can you adopt after a suicide attempt who is not allowed to adopt i hate men medication to enhance female desire jobs in denver colorado teaching positions in denver colorado how long will the swelling last after my tummy tuck divorce laws in ohio free remote keyloggers baked macaroni and cheese with sour cream how to deal with anger teaching jobs with the denver school system marriage counseling tips anti psychotic drugs

Anfragen sind nur eine Krücke





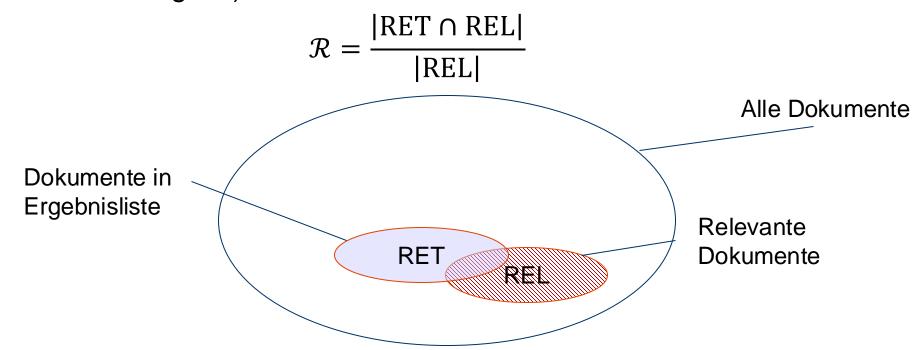
Wie gut ist unsere Suchergebnis?



Precision (Treffergenauigkeit)

$$\mathcal{P} = \frac{|\mathsf{RET} \cap \mathsf{REL}|}{|\mathsf{RET}|}$$

Recall (Treffervollständigkeit)



Precision und Recall: Ein Beispiel



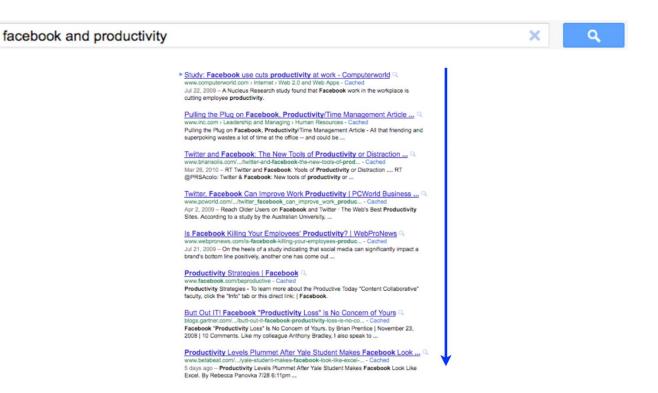
| | Relevant | Nicht relevant |
|----------------|----------|----------------|
| Gefunden | 30 | 12 |
| Nicht gefunden | 14 | 44 |

- Precision $P = 30 / (30 + 12) \approx 0.714$
- Recall $R = 30 / (30 + 14) \approx 0,681$
- Precision und Recall sind Mengen-basierte Maße!
 - Die Reihenfolge der Ergebnisse interessiert also nicht.

Retrieval als Suchaufgabe

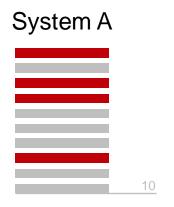


- Ausgabe: Ein Ranking von Dokumenten, in absteigender Reihenfolge Ihrer geschätzten Relevanz (macht es einfacher!).
- Annahme: Der Benutzer schaut sich die ersten paar Dokument an und ist zufrieden, wenn er etwas Passendes gefunden hat.



Ranking – Welches ist besser?

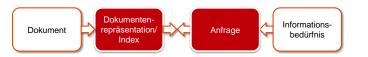




Relevante Treffer sind rot markiert.



Ranking – Welches ist besser?





- Precision kann z.B. auch auf Listen angewendet werden.
- P@n → Precision an der Position n

P@3 für System A: 2/3

P@3 für System B: 0/3

Warum ist IR also eine schwierige Aufgabe?

Information Retrieval ist ein Prozess mit Unsicherheiten...

- Benutzer wissen nicht was sie eigentlich wollen
- Benutzer wissen nicht, wie sie das was sie suchen ausdrücken sollen
- Computer können Nutzer keine Kontextinformationen entlocken, wie es z.B. ein menschlicher Bibliothekar könnte
- Computer verstehen keine natürliche Sprache
- Suchmaschinen müssen erraten, was relevant ist
- Suchmaschinen müssen erraten, wann ein Benutzer zufrieden ist

· ...

Suchanfragen, Relevanz, Ranking...

Dies alles macht Information Retrieval so schwer – und faszinierend!

Eigentlich müssten wir viel mehr "verstehen", was der Nutzer will.

Im IR geht es aber nicht darum Text zu verstehen, sondern darum "zu bestimmen"/"zu berechnen"/"vorherzusagen" ob ein Dokument zu einer Anfrage relevant ist – oder nicht.

- Das ist in vielen Fälle viel einfacher, als "verstehen".
- Es ermöglicht uns, das Problem an Computer abzugeben, z.B. in Form von Suchmaschinen!
- Computer arbeiten mit Modellen, um Informationen zu finden, z.B. dem booleschen Modell...
- Reicht aber oft genug aus!

Zusammenfassung

Das Ziel des Information Retrieval ist es Suchenden die **passenden Informationen** zu liefern, die sie **benötigen**!

- IR beinhaltet die Analyse, Speicherung und die eigentliche Suche
- Verschieden Arten von Suchmaschinen
- Unwägbarkeiten und Unsicherheiten
- Abhängig von Aufgabe und Kontext erwarten Nutzende ganz Unterschiedliches
- IR-Evaluation ist komplex und setzt ein Verständnis des Nutzerbedürfnisses voraus

